

Введение

Датасет взят с одного из соревнований kaggle, представляет собой данные о клиентах финансовой организации Home Credit Group. (<https://www.kaggle.com/competitions/home-credit-default-risk/overview>). Максимальный гос-аус на соревновании - 0.8

В данном случае решается задача бинарной классификации, вернет ли клиент ссуду или нет. Особенность данного датасета заключается в том, что все клиенты не имеют кредитной истории, и нужно при помощи дополнительной информации спрогнозировать платежеспособность клиента.

Одномерный анализ данных

Описательная статистика и визуализация распределений

Таблица 1 - Типы переменных


Категориальные	Непрерывные	Дискретные
"NAME_EDUCATION_TYPE" "NAME_HOUSING_TYPE"	"AMT_INCOME_TOTAL" "AMT_CREDIT" "AMT_ANNUITY" "AMT_GOODS_PRICE" "LIVINGAREA_AVG" "DAYS_EMPLOYED" "OWN_CAR_AGE"	"FLAG_OWN_CAR" "FLAG_OWN_REALTY" "CNT_CHILDREN" "TARGET"

Всего 307 511 записей. Данные имеют очень реалистичную структуру, практически все распределения сильно скошены и имеют выбросы, а целевая переменная имеет существенный дисбаланс. Ввиду этого на оригинальном соревновании и мы ориентировались в основном на метрику гос-аус. Ниже под таблицей 2 представлены интерпретации и визуализация распределений для каждой переменной в нашем датасете.

Таблица 2 - Ключевые описательные статистики


	count	mean	std	min	25%	50%	75%	max
FLAG_OWN_CAR	307 511.0	0.340	0.474	0.0	0.00	0.00	1.00	1.0
FLAG_OWN_REALTY	307 511.0	0.694	0.461	0.0	0.00	1.00	1.00	1.0
DAYS_EMPLOYED	307 511.0	63 815.046	141 275.767	-17 912.0	-2760.00	-1 213.00	-289.00	365243.0
AMT_INCOME_TOTAL	307 511.0	168 797.919	237 123.146	25 650.0	112 500.00	147 150.00	202 500.00	117 000 000.0
AMT_CREDIT	307 511.0	599 026.000	402 490.777	45 000.0	270 000.00	513 531.00	808 650.00	4 050 000.0
AMT_ANNUITY	307 499.0	27 108.574	14 493.737	1615.5	16 524.00	24 903.00	34 596.00	258 025.5
AMT_GOODS_PRICE	307 233.0	538 396.207	369 446.461	40 500.0	238 500.00	450 000.00	679 500.00	4 050 000.0
CNT_CHILDREN	307 511.0	0.417	0.722	0.0	0.00	0.00	1.00	19.0
OWN_CAR_AGE	104 582.0	12.061	11.945	0.0	5.00	9.00	15.00	91.0
LIVINGAREA_AVG	153 161.0	10.740	11.056	0.0	4.53	7.45	12.99	100.0
TARGET	307 511.0	0.081	0.272	0.0	0.00	0.00	0.00	1.0

1.FLAG_OWN_CAR, FLAG_OWN_REALTY - бинарные признаки без пропусков, имеют относительно небольшой дисбаланс | Владение машиной / собственностью



FLAG_OWN_CAR


$\mu = 0.34$ | $\sigma = 0.47$
skew = 0.68 | kurtos = -1.54



2. *DAYS_EMPLOYED* - признак с отрицательным знаком, без пропусков, имеет явный выброс или ошибку ввода 365243 (1000 лет) | Трудовой стаж на момент подачи заявки в днях (отриц.)

DAYS_EMPLOYED


$\mu = 63815.05$ | $\sigma = 141275.77$
skew = 1.66 | kurtos = 0.77



3. *AMT_INCOME_TOTAL* - сильно скошенный признак имеет огромные выбросы | Доход клиента

AMT_INCOME_TOTAL


$\mu = 168797.92$ | $\sigma = 237123.15$
skew = 391.56 | kurtos = 191786.55



4. *AMT_CREDIT*, *AMT_ANNUITY*, *AMT_GOODS_PRICE* - аналогично скошенные распределения, но с меньшими выбросами по сравнению с *AMT_INCOME_TOTAL*. Имеют пропуски | Размер кредита, размер платежа, и цена товара на который берется кредит




AMT_CREDIT

$\mu = 599026.00$ | $\sigma = 402490.78$
skew = 1.23 | kurtos = 1.93






AMT_GOODS_PRICE

$\mu = 538396.21$ | $\sigma = 369446.46$
skew = 1.35 | kurtos = 2.43



AMT_ANNUITY




$\mu = 27108.57$ | $\sigma = 14493.74$
skew = 1.58 | kurtos = 7.71



5. *CNT_CHILDREN*, *OWN_CAR_AGE*, *LIVINGAREA_AVG* - Правосторонняя асимметрия, наличие пропусков и выбросов | Количество детей клиента, возраст машины клиента и жилая площадь его дома




CNT_CHILDREN

$\mu = 0.42$ | $\sigma = 0.72$
skew = 1.97 | kurtos = 7.90




LIVINGAREA_AVG

$\mu = 10.74$ | $\sigma = 11.06$
skew = 2.85 | kurtos = 12.33




OWN_CAR_AGE



6. TARGET - целевая переменная сильный дисбаланс | 1 - клиент не вернул заем, 0 - вернул

TARGET




Первоначальное обучение
Удалили пропуски и преобразовали категориальные переменные
Roc-auc 0.55, f1 - 0.14, precision - 0.08, recall - 0.52, acc - 0,59


Обработка пропусков

Все признаки показывают сильную правостороннюю асимметрию, из-за этого среднее значение искажено. Для признаков AMT_ANNUITY, AMT_GOODS_PRICE в качестве момента заполнения пропусков используется медиана.
Признаки OWN_CAR_AGE, LIVING_AREA_AVG - имеют больше 70% пропусков, изначально мы их удалили. Потом попробовали сэмплировать из log-нормального распределения, и кажется получилось. При семплировании гос-аус вырос на 0.01.


LIVINGAREA_AVG



OWN_CAR_AGE




Пропуски в данных





Обработка выбросов

В признаке была найдена ошибка ввода или заглушка в виде числа 365243 (1000 лет), записей с этим числом было 55к. Было принято решение просто удалить эти записи и распределение приняло вид:




IQR мы применили к признакам AMT_INCOME_TOTAL и CNT_CHILDREN, и удалили выбросы




Все остальные признаки были прологарифмированы, в виду правой асимметрии, чтобы получить более нормальное распределение




AMT_CREDIT




AMT_GOODS_PRICE



OWN_CAR_AGE



AMT_ANNUITY



Результат

Метрики модели обученной на обработанных данных показали рост

Рос-аус 0.65, f1 - 0.22, precision - 0.14, recall - 0.39, acc - 0.74. Любое семплирование недостающего класса, приводило лишь к увеличению порога классификации, но не к качеству модели