



Введение

В работе используется тот же набор данных, что и в предыдущем задании после его улучшения с помощью методов многомерного анализа.

Первоначальный многомерный анализ



Видно, что лишь малая часть признаков коррелируют, например, AMT_GOODS_PRICE и AMT_CREDIT имеют корреляцию 0.99. Рассмотрим их диаграмму рассеяния.




На диаграмме явно прослеживается линейная зависимость данных признаков.
Также выведем признаки, имеющие наибольшую корреляцию с целевым признаком TARGET:

Корреляция с признаком TARGET:	
TARGET	1.000000
Secondary / secondary special	0.057605
With parents	0.027079
OWN_CAR_AGE	0.026488
Rented apartment	0.020142
Lower secondary	0.017092
CNT_CHILDREN	0.004982
Municipal apartment	0.002094
Incomplete higher	-0.000218
Co-op apartment	-0.000292
AMT_ANNUITY	-0.000974
FLAG_OWN_REALTY	-0.003084
Academic degree	-0.004948
Office apartment	-0.006701
AMT_CREDIT	-0.019062
House / apartment	-0.026644
AMT_INCOME_TOTAL	-0.028504
AMT_GOODS_PRICE	-0.030056
FLAG_OWN_CAR	-0.030293
LIVINGAREA_AVG	-0.033191
Higher education	-0.064177
DAYS_EMPLOYED	-0.074475
Name: TARGET, dtype: float64	


Ни один признак не имеет сильной корреляцией с целевым признаком.

Продвинутые методы многомерного анализа


Воспользуемся анализом главных компонент и выведем график кумулятивной объясненной дисперсии:



Семь компонент объясняют почти 90% дисперсии. Это указывает на то, что большая часть информации сосредоточена в меньшем количестве измерений.
Выведем количество объясненной дисперсии для каждой компоненты.



Представим многомерные данные в двумерном виде с помощью UMAP.




На данной проекции разными цветами помечены наблюдения с различными значениями целевого признака. Видно, что ни один “островок” не имеет большей концентрацией точек с значением целевого признака - 1. Проведем факторный анализ




Видно, что седьмой фактор хорошо объясняет признаки `AMT_CREDIT` и `AMT_GOODS_PRICE`. А первый фактор хорошо объясняет наличие высшего и второго образований.

Проведем кластерный анализ, для этого сперва определим оптимальное число кластеров. Воспользуемся методом локтя.



Оптимальное число кластеров составляет около 15. Проведем кластеризацию с помощью K-means и отобразим их на двумерной проекции, полученной с помощью UMAP.



Видно, что кластеризация четко не прослеживается на проекции, однако видны некоторые особенности. Так, например, у имеются “островки” со схожим разбиением на кластеры (оранжевый-фиолетовый-синий, оранжевый-красный, фиолетовый-черный).

Дополнительные методы создания признаков

Можно создать новые признаки на основе взаимодействия двух других

	DAYS_EMPLOYED_x_AMT_INCOME_TOTAL	AMT_CREDIT_x_SECONDARY_EDUCATION
0	78.911207	12.915581
1	88.554615	0.000000
2	60.275795	11.813037
3	94.735986	12.652947
4	93.887191	13.148033
...	...	...
239143	106.130564	12.712652
239144	65.437299	12.447846
239145	107.173982	0.000000
239146	102.102718	12.821550
239147	85.460616	0.000000

Также для генерации новых признаков можно воспользоваться полиномиальной генерацией. Возьмем пять числовых признаков и с помощью *PolynomialFeatures* сгенерируем для них все полиномиальные признаки второй степени: квадраты каждого признака и их попарные произведения.

FLAG_OWN_CAR	FLAG_OWN_CAR
AMT_INCOME_TOTAL	AMT_CREDIT
0.000000	0.000000
0.000000	0.000000
11.119898	11.813037
0.000000	0.000000
0.000000	0.000000

Для преобразования непрерывных признаков в категориальные можно воспользоваться биннингом. Применим его к признакам AMT_INCOME_TOTAL и DAYS_EMPLOYED. Выведем полученные бины.

	count		count
AMT_INCOME_TOTAL_BINS		DAYS_EMPLOYED_QUARTILES	
Income_Bin_1	496	DaysEmployed_Q1	59847
Income_Bin_2	13088	DaysEmployed_Q2	59749
Income_Bin_3	63324	DaysEmployed_Q3	59786
Income_Bin_4	109122	DaysEmployed_Q4	59766
Income_Bin_5	53118		

Отберем 10 наиболее важных признаков с помощью рекурсивного исключения признаков (RFE) с логистической регрессией. Рассмотрим получившиеся ранги признаков.

Ранг признака	
DAYS_EMPLOYED	1
AMT_GOODS_PRICE	1
AMT_ANNUITY	1
AMT_CREDIT	1
Lower secondary	1
Higher education	1
Academic degree	1
LIVINGAREA_AVG	1
With parents	1
Rented apartment	1
Office apartment	2
Incomplete higher	3
FLAG_OWN_CAR	4
OWN_CAR_AGE	5
Municipal apartment	6
House / apartment	7
AMT_INCOME_TOTAL	8
Secondary / secondary special	9
Co-op apartment	10
CNT_CHILDREN	11
FLAG_OWN_REALTY	12

Обучим модель после многомерного анализа, получилось увеличить roc-auc на 0.02, по сравнению с одномерным анализом

“Первоначальное обучение:
Удалили пропуски и преобразовали категориальные переменные
Roc-auc 0.55, f1 - 0.14, precision - 0.08, recall - 0.52, acc - 0,59”

После одномерного анализа:
Roc-auc 0.64, f1 - 0.21, precision - 0.14, recall - 0.39, acc - 0.74


После многомерного анализа

Порог классификации 0.11				
	precision	recall	f1-score	support
0	0.93	0.75	0.83	43690
1	0.14	0.44	0.22	4140
accuracy			0.72	47830
macro avg	0.54	0.59	0.52	47830
weighted avg	0.87	0.72	0.78	47830
ROC_AUC: 0.646329862458715				

Байесовские сети

Байесовскую сеть обучали, путем дискретизации данных
Прямое влияние на целевую переменную оказывают признаки DAYS_EMPLOYED и Higher Education. DAYS_EMPLOYED: У дефолтных клиентов пики в определенных интервалах (категории 3, 5, 6 заметно выделяются). При помощи байесовской сети мы сэмплилировали записи с недостающим классом и обучили модель на дискретных данных. Увеличился порог классификации, но не качество модели, при дискретизации потерялась значительная часть информации

Порог классификации 0.32					
	precision	recall	f1-score	support	
0	0.93	0.77	0.85	43744	
1	0.14	0.39	0.21	4137	
accuracy			0.74	47881	
macro avg	0.54	0.58	0.53	47881	
weighted avg	0.86	0.74	0.79	47881	
ROC_AUC: 0.6302241371513236					



Заключение

Наибольший прирост к метрикам, выдал одномерный анализ. При помощи многомерного анализа получилось еще на пару пунктов поднять roc-auc.