



ІТМО

Лабораторные работы

3-4

Команда 14

Бухтояров Вячеслав
Анненков Илья
Ломакина Александра
Аббкова Виктория

Данные - Home Credit Group

Задача: Бинарная классификация, предсказание неплатежеспособности клиента Home Credit Group



307 511 записей, 12 признаков и 1 целевая переменная

Категориальные

"NAME_EDUCATION_TYPE"
"NAME_HOUSING_TYPE"

Дискретные

"FLAG_OWN_CAR"
"FLAG_OWN_REALTY"
"CNT_CHILDREN"
"TARGET"


Непрерывные

"AMT_INCOME_TOTAL"
"AMT_CREDIT"
"AMT_ANNUITY"
"AMT_GOODS_PRICE"
"LIVINGAREA_AVG"
"DAYS_EMPLOYED"
"OWN_CAR_AGE"

Источник: <https://www.kaggle.com/competitions/home-credit-default-risk/data>


Логистическая регрессия (сырые данные)

	precision	recall	f1-score	support
0	0.95	0.59	0.73	9320
1	0.08	0.52	0.14	617
accuracy			0.59	9937
macro avg	0.51	0.56	0.43	9937
weighted avg	0.90	0.59	0.69	9937
ROC_AUC: 0.5572383156767134				



Одномерный анализ и его результаты


Пропуски в данных




Обработка пропусков



Исходное распределение




Сэмплирование пропусков из того же распределения



Одномерный анализ и его результаты

Обработка выбросов

Исходное распределение




Убрали
заглушку






применили
IQR



Распределение после
обработки





DAYS_EMPLOYED

 $\mu = 2384.17$ | $\sigma = 2338.36$
 skew = 1.97 | kurtos = 4.75





AMT_CREDIT

 $\mu = 599026.00$ | $\sigma = 402490.78$
 skew = 1.23 | kurtos = 1.93





AMT_GOODS_PRICE

 $\mu = 538396.21$ | $\sigma = 369446.46$
 skew = 1.35 | kurtos = 2.43


OWN_CAR_AGE

 $\mu = 12.06$ | $\sigma = 11.94$
 skew = 2.75 | kurtos = 9.21




AMT_ANNUITY

 $\mu = 27108.57$ | $\sigma = 14493.74$
 skew = 1.58 | kurtos = 7.71





Логарифмирование






DAYS_EMPLOYED




AMT_CREDIT






AMT_GOODS_PRICE



OWN_CAR_AGE



AMT_ANNUITY



Обучение после преобразования

Порог классификации 0.11



	precision	recall	f1-score	support
0	0.93	0.78	0.85	43744
1	0.14	0.39	0.21	4137
accuracy			0.74	47881
macro avg	0.54	0.58	0.53	47881
weighted avg	0.86	0.74	0.79	47881

ROC_AUC: 0.6335726595009724

Метрики модели обученной на обработанных данных показали рост


Roc-auc 0.63, f1 - 0.21, precision - 0.14, recall - 0.39, acc - 0.74

Первоначальный многомерный анализ








Зависимость кумулятивной объяснённой дисперсии от числа компонент





Объяснённая дисперсия для главных компонент



Продвинутые методы многомерного анализа





Дополнительные методы создания признаков





	DAYS_EMPLOYED_x_AMT_INCOME_TOTAL	AMT_CREDIT_x_SECONDARY_EDUCATION
0	78.911207	12.915581
1	88.554615	0.000000
2	60.275795	11.813037
3	94.735986	12.652947
4	93.887191	13.148033
...	...	...
239143	106.130564	12.712652
239144	65.437299	12.447846
239145	107.173982	0.000000
239146	102.102718	12.821550
239147	85.460616	0.000000

AMT_INCOME_TOTAL_BINS

	count
Income_Bin_1	496
Income_Bin_2	13088
Income_Bin_3	63324
Income_Bin_4	109122
Income_Bin_5	53118

Дополнительные методы создания признаков





Сэмплировали недостающий класс и обучили

Порог классификации 0.32

	precision	recall	f1-score	support
0	0.93	0.77	0.85	43744
1	0.14	0.39	0.21	4137
accuracy			0.74	47881
macro avg	0.54	0.58	0.53	47881
weighted avg	0.86	0.74	0.79	47881

ROC_AUC: 0.6302241371513236

Спасибо
за внимание!

it's **MO** *re than a*
UNIVERSITY